

1차 모임

박은지

대학생 맞춤 대외활동/공모전 추천 AI

대외활동이나 공모전 데이터를 모아서 사용자의 관심분야나 지역, 참여 조건 등에 맞는 공고를 추천

최종적으로 RAG를 활용하여 실제 공고를 기반으로 추천 이유까지 알려주는 방식

링크리어나 같은 대외활동 사이트의 API는 공개 API가 없음. 프로젝트 목적 크롤링이 가능한지 문의하고 데이터 확보해야 함.

멘토님 조언:

- API가 따로 제공되지 않는다면 매일 또는 매주 시간을 걸어두고 데이터를 실시간으로 크롤링 해오는 방식을 적용할 수 있음.
- <https://github.com/jongwyyi/career-mcp> 재정경제부 공공기관 채용정보 API와 사람인 API를 활용해서 대학생 개인의 인턴, 신입 채용 매칭 도구 개발(참고용)

보충내용

프로젝트 배경

대학생들이 대외활동이나 공모전을 찾을 때는 여러 플랫폼에 등록된 많은 공고를 직접 탐색해야 한다.

기존 방식의 문제점

- 여러 사이트를 직접 방문해야 함
- 자신의 관심 분야와 맞는 공고를 직접 탐색해야 함
- 지원 대상, 지역, 모집 기간 등의 조건을 일일이 확인해야 함
- 단순 카테고리-키워드 검색만으로는 자신의 관심사와 실제로 얼마나 관련 있는지 판단하기 어려움
- 새로운 공고가 계속 등록되므로 반복적인 정보 탐색이 필요함

해결 방향

공고 데이터 자동 수집 + 개인화 추천 + RAG 기반 추천 설명

사용자의 조건과 관심사를 분석하여 지원 가능한 공고 중 적합도가 높은 공고를 자동으로 추천한다.

프로젝트 목표

대외활동·공모전 데이터를 주기적으로 자동 수집하고, Metadata Filtering과 Embedding Similarity를 활용해 개인화된 공고를 추천하며, RAG를 통해 실제 공고 정보를 근거로 추천 이유를 생성한다.

핵심 기술

- Web Crawling
- Scheduler
- Data Preprocessing
- Metadata Filtering
- Embedding
- Cosine Similarity
- Vector DB
- RAG

- LLM

전체 서비스 구조

```

대외활동·공모전 사이트
↓
주기적 자동 크롤링
↓
데이터 전처리
↓
중복 공고 확인
↙      ↘
기존 공고      신규 공고
↓            ↓
변경사항 갱신      DB 저장
↓
Embedding 생성 / 갱신
↓
공고 DB + Vector DB
|
|
사용자 프로필 입력
↓
Metadata Filtering
↓
Embedding Similarity
↓
추천 후보 Ranking
↓
Top-K 공고 검색
↓
RAG
↓
LLM
↓
맞춤 공고 + 추천 이유
  
```

데이터 수집

온통청년 (정부 사이트, api 발급가능)

주기적 자동 크롤링

초기에 한 번 데이터를 수집하고 끝내는 것이 아니라 **Scheduler**를 이용하여 일정 주기로 새로운 공고를 자동 수집한다.

예시

```

매일 새벽 3시
↓
Crawler 실행
↓
최신 공고 목록 확인
↓
신규 / 기존 공고 구분
↓
DB 업데이트
  
```

수집 주기

초기 MVP에서는 **1일 1회** 정도를 고려.

공모전-대외활동은 초 단위로 정보가 변하는 서비스가 아니므로 실시간 요청마다 크롤링할 필요성이 낮다.

주기적 자동 크롤링(Scheduled Crawling)

크롤링 대상 사이트 조사

① 위비티

위비티

현재 공개 공고 페이지에서 다음과 같은 정보가 확인된다.

- 공고 제목
- 분야
- 응모 대상
- 주최/주관
- 접수 기간
- 상금
- 공고 상세 내용
- 원문 홈페이지

실제 상세 페이지에서도 이러한 정보가 구조적으로 제공되고 있어 **추천 시스템에 필요한 Metadata 확보가 비교적 용이해 보인다.**

Wevity.

또한 공모전 목록이 카테고리별로 공개되어 있어 신규 공고 탐색에도 활용할 수 있다. Wevity.

주요 전처리

- HTML 태그 제거
- 날짜 형식 통일
- 모집 대상 정규화
- 활동 분야 정규화
- 지역 정보 정규화
- 마감된 공고 구분
- 중복 공고 제거

사용자가 **실제로 지원할 수 있는** 공고를 먼저 선별한다.

Metadata Filtering

활용 Metadata

- 지원 대상
- 학년
- 지역
- 활동 유형
- 모집 여부
- 마감일
- 관심 분야

Embedding Similarity

Metadata Filtering을 통과한 공고 중 **사용자의 관심사와 의미적으로 유사한 공고**를 탐색한다.

예시 사용자 입력

AI를 이용해서 실제 데이터를 분석하고 모델을 만들어보는 프로젝트를 경험하고 싶다.

추천 Ranking⇒ top-k공고 선정

RAG: 추천된 공고의 실제 정보를 검색하여 LLM에게 제공함

프로젝트의 차별점

일반적인 대외활동 검색 서비스는 사용자가 직접 조건을 설정하고 검색해야 함

자동 데이터 수집 → 개인 조건 필터링 → 의미 기반 추천 → RAG 설명

따라서 단순히 “GPT API를 이용한 공모전 추천 챗봇”이 아니라, **실제 데이터를 지속적으로 구축·갱신하면서 동작하는 AI 추천 시스템**을 목표로 한다.

차지민

프로젝트 맞춤 오픈소스 추천 AI agent

사용자가 필요한 오픈소스나 모듈을 입력하면 호환성이나 유지보수 여부랑 성능을 고려해서 추천

깃허브 api, 허깅페이스 api 사용해서 데이터 추출

멘토님 조언:

일반적으로 codex나 클로드 코드 같은 LLM에게 프로젝트 상황을 설명하고 적합한 오픈소스를 추천해 달라고 요청하는 것과 비교했을 때 어떤 차별점을 가져갈 수 있을 지 고민해보기

보안 내용

필요한 데이터

깃허브 API: README, Issues 같은 비정형 데이터.

허깅페이스 API: 모델 계열 추천에 씬

PyPI/npm API: 실제 설치 가능한 버전과 의존성 범위, 사용자가 이미 쓰는 라이브러리와 충돌하는지 확인하는 용도

대략적인 흐름

사용자 조건 입력 → GitHub/HF에서 후보 검색 → license/버전 등으로 필터링 → 남은

후보의 README와 Issues를 RAG로 검색해서 근거 수집 → 필요하면 실제 설치해서 호환성

확인 → 근거와 함께 비교표로 제시(출력)

코딩 에이전트와의 차이

Claude Code 같은 도구도 라이브러리를 고를 때 근거를 보고 판단하기 때문에 큰 틀에서는 비슷하다. 차이가 있다면 Issues까지 명시적으로 대조해서 근거로 보여주는 부분에서 신뢰도를 좀 더 높일 수 있다는 정도이다.

이선

화장품 화학 성분 기반 스킨케어 추천

화학성분 데이터를 기준으로 피부 타입에 맞는 스킨케어 추천

사용자의 피부타입, 피부 고민에 맞는 스킨케어 제품을 추천한다.

참고 데이터

- 식품의약품안전처_화장품 원료성분정보(오픈 API)
 - <https://www.data.go.kr/data/15111774/openapi.do>
- 스킨케어 성분-효능 추천 데이터
 - <https://aihub.or.kr/aihubdata/data/view.do?pageIndex=1&currMenu=115&topMenu=100&srchOptnCnd=OPTNCND001&searchKeyword=화장&srchDetailCnd=DETAILED001&srchOrder=ORDER001&srchPagePer=20>
- 문제성 피부 메이크업 추천 데이터
 - <https://aihub.or.kr/aihubdata/data/view.do?pageIndex=1&currMenu=115&topMenu=100&srchOptnCnd=OPTNCND001&searchKeyword=화장&srchDetailCnd=DETAILED001&srchOrder=ORDER001&srchPagePer=20&aihubDataSe=data&dataSetSn=71961>
- 의약품, 화장품 패키징 OCR데이터 (정부에서 공개한 화장품 용기/상품 라벨 텍스트 데이터셋)
 - https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=633&utm_source=gemini

성분 추천 데이터 수집=> 직접 구축해야 됨...

- <https://www.paulaschoice.co.kr/ingredient-dictionary> 스킨케어 성분 사전
- <https://inkeedecoder.com/> INCIDecoder 웹 크롤링

멘토님 조언:

<https://github.com/LeeJaeln04/DermaRAG-Chatbot> 깃허브 참고

보안내용

1. 데이터 수집: 공개 API, 오픈데이터, 크롤링
2. 데이터 정제 (중복 제거, 결측 처리, 성분 분리, 표기 통일)
3. DB저장: product(제품ID, 이름, 브랜드, 카테고리, 가격), ingredients(성분ID, 성분명, 효능 태그, 주의사항), product_ingredients(제품ID, 성분ID, 성분 순서) ⇒ LLM이 잘못된 정보를 말하지 않도록 DB를 만든 후 DB 안에서 말하도록 해야 함.
4. 성분태깅
 - 고민별로 매칭되는 성분을 정해두면 규칙이 명확

예시

- 건조함 → 히알루론산, 세라마이드
- 트러블/여드름 → 살리실산(BHA), 나이아신아마이드
- 홍조/민감 → 병풀추출물(시카), 판테놀
- 칙칙함 → 비타민C, 나이아신아마이드

5. 사용자 입력 해석
6. 후보 필터링⇒ LLM에 넘기기 전 후보 좁히기
 - 기피 성분이 들어간 제품 제외
 - 효능 태그를 가진 성분이 포함된 제품 선택
 - 예산과 카테고리 조건 적용

7. LLM추천 생성

프롬프트에 넣을 내용: 사용자 조건, 후보 제품 목록, 규칙(ex. 성분 기준으로 이유 설명, 성분 충돌 경고)

8. 화면 구성

입력: 피부타입 선택, 고민 다중 선택, 자유 입력창, 기피 성분

출력: 제품, 이유, 주의사항

피드백: 도움됐어요/아니예요 버튼 → DB에 저장

이용재

무인점포 창업을 위한 서울특별시 구별 소상공인 상권 분석 및 무인화 적합도 안내 AI

상권 정보, 유동 인구, 무인점포 수, 임대료 등의 데이터를 AI에 학습시켜 구별 동종 업계의 경쟁률과 폐업률 등을 사용자에게 안내하고, 적합한 입지를 추천하는 시스템

이를 통해 창업자가 경쟁이 치열한 지역에 무작정 뛰어드는 것을 막고, 데이터상 생존 가능성이 높은 지역을 찾도록 돕는 나침반 역할을 할 수 있음.

참고 데이터

- 소상공인시장진흥공단_상가(상권)정보
 - <https://www.data.go.kr/data/15083033/fileData.do>
- 국토교통부_주요상권
 - <https://www.data.go.kr/data/15028102/openapi.do>
- 소상공인시장진흥공단_전국 상권 현황
 - <https://www.data.go.kr/data/15143727/fileData.do>
- 서울특별시_자치구단위 서울생활인구 일별 집계표
 - <https://www.data.go.kr/data/15083611/fileData.do>
- 서울특별시_무인점포 현황
 - <https://www.data.go.kr/data/15157977/fileData.do>

멘토님 조언:

다양한 데이터를 어떻게 통합해서 활용할 지, 활용한다면 어떻게 활용할 수 있을지 고민해보기

보안내용

데이터구성

데이터/확인한내용/챗봇에서의역할

상가(상권)정보(2026.06)/서울약55만점포/지역별전체경쟁점포수(유인점포포함)

주요상권현황(2024.01)/서울176개상권경계좌표/점포가번화가상권안에있는지판별

서울시무인점포현황/4,251개,6개업종,자치구단위/자치구별무인점포수(무인경쟁강도)

자치구단위생활인구(일별)/2018.04~2026.07,주간/야간구분/수요지표(업종별로주간·야간인구선택)

비정형데이터:검색용(추가수집예정)

데이터통합방법

무인점포 현황과 생활인구가 자치구 단위라서 공통 분석 단위를 자치구 × 업종(25개 구 × 6개업종)으로 정함

각 데이터에서 다음과 같이 값을 뽑아 한 테이블로 합침

상가정보: 좌표로 주요상권 포함 여부를 판별한 뒤, 구·업종별 전체 점포 수와 주요상권 내 비율을 집계

무인점포 현황: 구·업종별 무인점포 수 집계 (자치구 이름 표기 통일 필요, 예: "중" → "중구")

생활인구: 최근 기간 평균으로 집계하고, 서울시 전체 합계 행은 제외

파생 지표: 생활인구 1만 명당 무인점포 수, 유인 점포 대비 무인점포 비율 등

데이터를 직접 결합해 보며 두 가지를 확인

첫째, 상가정보에서 무인 아이스크림점은 대부분 '슈퍼마켓'으로 분류되어 있어 상가정보만으로는 무인점포 경쟁을 셀 수 없음. 그래서 무인점포 수는 무인점포 현황에서, 전체 경쟁 점포는 상가정보에서 가져와 역할을 나눔

둘째, 셀프 빨래방은 주요상권 안에 있는 비율이 7%로 사진관(27%)보다 훨씬 낮은 주거지형 업종 따라서 업종마다 다른 수요 지표(빨래방은 야간인구, 사진관은 주간인구)를 적용.

챗봇에서의 사용 방식

통합 테이블은 두 가지 방식으로 LLM에 연결

도구(Tool) 호출: LLM이 질문을 해석해 테이블을 조회하거나 SQL을 실행. 숫자는 LLM이 기억으로 답하지 않고 항상 실제 조회 결과를 사용하므로 수치 환각을 막을 수 있음.

상권 요약 문서화: 구·업종별 수치를 "관악구 무인 빨래방: 생활인구 1만 명당 무인점포 수 서울 1위..." 같은 짧은 문장 카드로 만들어 벡터 DB에 넣기. 이때 구와 업종을 메타데이터로 달아 검색 시 필터링.

비정형 문서는 청크 단위로 나눠 임베딩하고, 업종 태그를 메타데이터로 붙여 같은 업종 문서만 우선 검색되게 합니다.

답변 흐름 예시

사용자: "관악구에 무인 빨래방 창업하려는데 괜찮을까?"

질문에서 지역(관악구)과 업종(빨래방) 추출

통합 테이블 조회 → 무인점포 밀도, 야간인구, 전체 세탁 관련 점포 수

문서 검색 → 셀프 빨래방 창업 절차, 관련 지원사업

LLM이 수치와 문서를 종합해 답변하고, 근거 출처를 함께 표시합니다