

데이터사이언스 1조 발표

AI의 눈을 가리는 마법의 스티커

실시간 객체 인식 교란 적대적 패치(Adversarial Patch) 구현

딥러닝 객체 인식 모델(YOLO, ResNet 등)이 사람을 인식하지 못하거나 다른 사물(예: 바나나)로 오분류하도록 만드는 특수 패턴의 스티커를 제작하고, 이를 웹캠 환경에서 실시간으로 시연합니다.

기획 의도 및 배경

왜 이 프로젝트인가?

01 AI 보안의 취약점

자율주행차, CCTV 등 시각 기반 AI가 실생활에 깊숙이 들어왔지만, 치명적인 보안 취약점이 존재함.

02 물리적 위협의 현실화

해킹으로 시스템에 침투하지 않아도, 스티커 한 장이라는 단순한 물리적 조작만으로 AI의 판단을 무너뜨릴 수 있음.

03 시각적 임팩트

실제 카메라 앞에서 AI가 속는 과정을 보여주어 흥미와 경각심을 함께 유발.

핵심 원리 1 — 적대적 공격(Adversarial Attack)

편미분을 입력층까지 끌고 오는 신박한 발상.

일반적인 AI 학습

입력 이미지 고정 · 가중치(W) 수정 · Loss 감소

$$W \leftarrow W - \eta \cdot \partial L / \partial W$$

정답을 맞히도록 Loss를 가중치로 편미분해
기울기 반대 방향으로 이동 (경사하강법)

적대적 공격

가중치 고정 · 입력 픽셀(x) 수정 · Loss 증가

$$x \leftarrow x + \epsilon \cdot \text{sign}(\partial L / \partial x)$$

오답을 내도록 Loss를 이미지 자체로 편미분해
기울기 부호 방향으로 이동 (Gradient Ascent)

약점 찌르기: 기울기의 부호가 말해주는 것

$$\partial L / \partial a > 0$$

픽셀 a의 값을 키울수록 Loss가 증가 → a를 증가시킨다

$$\partial L / \partial a < 0$$

픽셀 a의 값을 줄일수록 Loss가 증가 → a를 감소시킨다

핵심 원리 2 — 국소적 공격, 적대적 패치

마스킹(Masking)

길거리 CCTV 화면 전체의 픽셀은 조작할 수 없습니다.
그래서 스티커 크기의 특정 영역에만
교란 픽셀을 집중시킵니다.




$$\mathbf{x}' = (1 - \mathbf{M}) \odot \mathbf{x} + \mathbf{M} \odot \mathbf{P}$$

M: 패치 자리만 1인 마스크

P: 학습되는 패치 픽셀

전이성(Transferability)

타겟 AI의 내부 구조를 몰라도 괜찮습니다.
공개된 상위 모델을 완벽히 속이는 패치는
비슷한 특징을 쓰는 다른 모델도 연쇄적으로 속입니다.



핵심 원리 3 —EOT, NPS

프린터로 뽑으면 실패하는 이유

화면 속 패치를 그대로 인쇄하면 조명, 카메라 각도, 구겨짐, 거리 변화 때문에 교란 효과가 즉시 사라집니다.

EOT

Expectation Over Transformation

패치를 업데이트하기 전에 무작위로 회전, 축소, 명암 조절을 거쳐 배경에 합성하는 데이터 증강을 통해 강건성을 확보합니다.

회전

크기 변화

명암 변화

배경 합성

악조건에서도 살아남는 패치를 얻습니다.

NPS

Non-Printability Score

모니터(RGB)의 색 중 일부는 프린터(CMYK)로 인쇄하면 변질됩니다. 그래서 처음부터 인쇄 가능한 색 범위 안에서만 픽셀이 업데이트되도록 제한합니다.

RGB

→

CMYK

인쇄 후에도 설계한 색이 유지됩니다.


프로젝트 구현 방안 (Architecture & Workflow)

1	모델 준비	YOLO 또는 ResNet 기반의 경량 객체 인식 모델 세팅
2	패치 초기화	무작위 노이즈 이미지 생성
3	EOT 합성	사람 이미지 위에 패치를 합성하며 회전, 크기 조절 등 변형 적용
4	Loss 계산	사람을 바나나(예시)로 분류하거나 인식 불가로 만드는 Loss 계산
5	패치 업데이트	역전파를 통해 오직 패치 영역의 픽셀값만 업데이트
6	인쇄 및 보정	생성된 패치 이미지를 컬러 프린터로 인쇄

← 학습 루프
수만 번 반복


실시간 시연 및 예상 결과 (Demo)

Before



웹캠 앞에 사람이 서면
[Person: 99%] 바운딩 박스가 정상적으로 잡힙니다.

After



인쇄한 패치를 가슴 높이에 드는 순간,
박스가 사라지거나 [Banana: 85%]로 오인합니다.

고도화된 AI가 특정 패턴 하나에 얼마나 쉽게 무너질 수 있는지를 직관적으로 증명.