

2026년 2학기 COW AI팀 · AI 엔지니어링 트랙 2조 — 3주차 실습 진행 발표

피부 타입 · 성분 기반 화장품 추천 RAG AI

3주차 진행 발표 — 데이터 수집 현황 · 전처리 · EDA

2026. 10. 7. · 3주차 · 데이터 전처리 / EDA / 시각화

AI 엔지니어링 2조 이용재

데이터베이스 구축 방향 (멘토 제안)

정확한 단어 매칭인 RDB 대신, 데이터를 CSV로 먼저 구축한 뒤 Vector DB로 변환한다

⚠ RDB 검색의 한계

SQL **WHERE** 절은 단어가 **정확히 일치**해야 결과를 찾는다

WHERE 성분명 = '히알루론산'

→ 표기가 다르거나 오타가 있으면 결과 없음

사용자 오타, 복잡한 화장품 성분명(히알루론산, 글리세린 등) 검색에서 결과를 놓칠 수 있음

약 45% 우리 데이터에서도 확인 — 고유 표기 기준 식약처 성분명과 일치하는 비율

💡 제안: CSV → Vector DB (+ 필요 시 RDB)

- 1 CSV로 1차 구축**
크롤링·수집 데이터를 먼저 CSV 파일로 정리



- 2 Vector DB로 변환**
추천과 1차 데이터 구축에는 Vector DB 사용 권장



- + 필요할 때 RDB 추가**
사용자 추천 정보·피드백 등을 활용해야 할 때 구성

👉 그래서 이번 단계의 1차 범위는 **Vector DB 변환 이전까지** — 데이터 수집 · CSV 생성 · 전처리 · EDA/시각화

크롤링 · 수집 방식과 역할 분담

공통 크롤링 코드를 AI로 만들고, 2명씩 조를 나누어 데이터를 모았다

올리브영 제품 데이터

은지 · 지민

제품 / 성분 / 사용법 크롤링

제품명

성분

사용 방법

피부 타입 / 주의사항

식약처 원료 데이터

용재 · 선

성분 데이터 수집 / 변환

화장품 성분 데이터

원본 → 통합 엑셀 변환

</> 크롤링 진행 방식

① 프롬프트 작성

수집 항목과 CSV 출력 형태를 정의



② AI로 코드 작성·실행

ChatGPT, Claude 등으로 크롤링 코드 생성



③ 공통 코드 분담 실행

한 명이 공통 코드를 만들고 페이지를 나눠 함께 실행



④ CSV 파일 생성

Vector DB로 변환할 1차 데이터

1차 목표

데이터 수집

CSV 생성

전처리

EDA · 시각화

Vector DB 변환 이전 단계까지

수집 결과: 1차 데이터 구축 완료

올리브영 제품 파일 3종과 식약처 통합 원료 파일을 만들어, Vector DB로 옮길 준비를 마쳤다

📖 제품 데이터 — 올리브영 크롤링

은지 · 지민

파일 ① 클렌징 · 선크어 · 더모코스메틱 2,460개

16개 컬럼: 브랜드, 판매가·정가, 리뷰 수, बै지, 용량, 전성분, 사용법, 주의사항 등

파일 ② 스킨케어 1,341개

스킨/토너, 에센스/세럼/앰플, 크림, 로션, 미스트/오일

파일 ③ 마스크팩 810개

시트팩, 페이스팩, 패드, 패치, 코팩

파일 ②·③은 18개 컬럼 — 피부 타입(제품 주요 사양), 사용기한, 제조국, 전성분 등

🔍 원료 데이터 — 식약처

용재 · 선

식약처 원본 4종 → 엑셀 1개로 통합

성분사전

21,945건

국가별 금지·한도 원료

31,191건

사용제한 원료

7,257건

금지·제한 국가 요약

7,257건

정리 결과: 성분 27,620개 (한글 표준명 기준 중복 제거)

시트 3개 — 성분목록 / 성분상세 / 국가별규제

성분마다 위험 · 주의 · 안전 판정과 판정 근거를 붙임

4,292개

제품 (중복 제외)

약 500개

브랜드

27,620개


성분

31,191건

규제 레코드

데이터 활용 구조: CSV → Vector DB → RAG

제품과 원료는 '성분명(한글)'으로 이어지고, 그 결과가 LLM 답변의 근거가 된다



두 데이터를 잇는 키는 '**성분명(한글)**'이다

→ 전처리의 핵심은 전성분 텍스트를 성분 단위로 정확히 쪼개 매칭하는 것

RDB만 쓰면

정확히 같은 단어만 찾아서 오타·표기 차이에 약함

Vector DB를 쓰면

의미가 가까운 제품·성분 문서를 함께 검색

그래도 전처리가 필요한 이유

성분 분리·정규화가 매칭 품질을 결정

데이터 품질 점검 결과

결측치 · 이상치 · 중복을 점검했고, 평점 컬럼은 크롤링 오류로 쓸 수 없다

항목	발견 내용	처리 방안
결측치	전성분 누락: 파일 ① 19건 , ② 9건 , ③ 7건 크롤링 status가 partial인 행 17건	전성분이 없으면 추천 근거가 없음 → 제외하거나 재크롤링
이상치	평점이 2,460개 전부 "10점만점에 5.5점"으로 같은 값 → 크롤링 오류	오류난 평점 컬럼은 사용하지 않고, 크롤러를 수정한 뒤 재수집
상한 절삭	리뷰 수 956개(39%) 가 "999+"로 표시되어 실제 값을 알 수 없음	범주형(인기 상·중·하)으로 변환
중복	파일 간 같은 상품번호(goods_no) ①-② 244개 · ①-③ 73개 · ②-③ 1개	goods_no 기준으로 병합하고 중복 제거
불필요한 텍스트	제품명 뒤 "이 올리브영" 접미사, "기획·증정·1+1·대용량" 같은 판촉 문구 다수 (기획 1,564건)	정규식으로 정제, 판촉 문구는 별도 컬럼으로 분리

전처리 핵심: 전성분 텍스트 파싱

등장 횟수 기준 약 96%가 매칭되지만, 고유 표기 기준으로는 약 45%뿐이다

문제 1 · 쉽표 단순 분할

"1,2-헥산다이올" → "1" + "2-헥산다이올"로 깨짐 (최다 빈도 성분인데 매칭 실패)

문제 2 · 기획세트 표기

"[본품]", "[증정]", "*", 함량 "(2,100ppm)"이 섞여 있음

문제 3 · 띄어쓰기 차이

"살리실릭 애씨드" vs "살리실릭애씨드"

① 숫자 사이 쉽표 보호



② 괄호 안 함량 제거



③ [구성품]* 표기 제거



④ 공백 정규화



⑤ 식약처 표준명(이명 포함) 매칭

Before

[본품] 정제수, 1,2-헥산다이올, 나이아신아마이드(2,100ppm)*, 살리실릭 애씨드

After

정제수

1,2-헥산다이올

나이아신아마이드

살리실릭애씨드

예시

약 46개

제품당 평균 성분 수 (중앙값 38개)

약 11,000종

고유 성분 표기

약 96%

매칭률 · 성분 등장 횟수 기준


약 45%

매칭률 · 고유 표기 기준 → 정규화가 남은 과제


EDA ① 제품 데이터

자주 나오는 성분은 대부분 베이스 성분이라, 추천에는 기능성 성분 가중치가 필요하다

카테고리별 제품 수



판매가 분포 (파일 ① · 범위·중앙값·평균)



상위 빈출 성분 Top 10



💡 상위 성분은 대부분 베이스(용매·보습·보존) 성분이라 차별성이 낮다 → 추천에는 기능성 성분(나이아신아마이드, 아데노신, 살리실릭애씨드 등) 가중치가 필요

EDA ② 피부 타입 & 원료 안전성

피부 타입 정보는 거의 없고, 성분명 단순 매칭으로는 위험을 정확히 판정할 수 없다

발견 1 · 피부 타입 정보가 거의 없음

약 90% 스킨케어·마스크팩 2,135개 중 "모든 피부용"뿐

45

건성

70

민감

24

지성

21

복합

파일 ①에는 피부 타입 컬럼이 아예 없음


대응: 피부 타입-성분 규칙을 지식 베이스로 구축

지성 → 살리실릭애씨드

건성 → 세라마이드 · 하이알루로닉애씨드

민감 → 향료 · 에센셜오일 주의

발견 2 · 원료 판정 분포



■ 안전

20,698 (75%)

■ 주의

3,557 (13%)

■ 위험

3,365 (12%)

발견 3 · 판정 기준이 너무 거칠다

판정을 제품에 그대로 적용하면

35%

제품에 "위험" 성분

95%

제품에 "주의" 성분

글리세린 → 캐나다에 한도 규정이 있어 "주의"

탈크 · 트로메타민 → 조건부 규제 원료인데 이름만으로 매칭되어 "위험"



결론: 성분명 단순 매칭 판정은 오탐이 많다 → 규제 조건(함량 한도·용도·불순물 기준)을 원문 텍스트로 함께 저장하고, LLM이 근거를 인용해 설명하도록 RAG 설계



"안전" = 규제 목록에 없다는 뜻이지, 자극·독성 평가 결과 아니다

1차 목표 달성 & 데이터 활용 방안

Vector DB 변환 이전 단계까지 마쳤고, 정제된 데이터는 RAG 지식 베이스의 근거가 된다

☑ 1차 목표 — 달성한 것

✓ **데이터 수집**
제품 4,292개 · 성분 27,620개 · 규제 31,191건

✓ **CSV · 통합 파일 생성**
제품 파일 3종 + 식약처 통합 엑셀(시트 3개)

✓ **전처리**
결측·이상치·중복 처리, 전성분 파싱 (등장 기준 매칭 약 96%)

✓ **EDA · 시각화**
카테고리 · 가격 · 빈출 성분 · 피부 타입 · 판정 분포

💡 정제 데이터 활용 방안

성분 단위로 쪼갬 전성분 → 제품·성분 문서
Vector DB에 넣을 문서로 사용 — RDB 정확 매칭의 한계 보완

성분 표기 정규화 사전
이명 · 띄어쓰기 · 영문명으로 고유 표기 매칭률(약 45%) 개선

피부 타입-성분 규칙
약 90%가 "모든 피부용"인 문제를 성분으로 추론해 보완

규제 조건 원문 + 판정 근거
LLM이 근거를 인용해 설명 — 단순 매칭 판정의 오탐 방지

</> **산출물 공유** — 전처리 코드와 정제 데이터셋을 [COW-AI-Project-2026-2](#) 레포에 PR로 올림

감사합니다

Q&A