COW AI팀
데이터사이언스트랙
2조
5주차 프로젝트 발표

변수 선택, 전처리 변화와 개선된 알고리즘으로 성능 개선

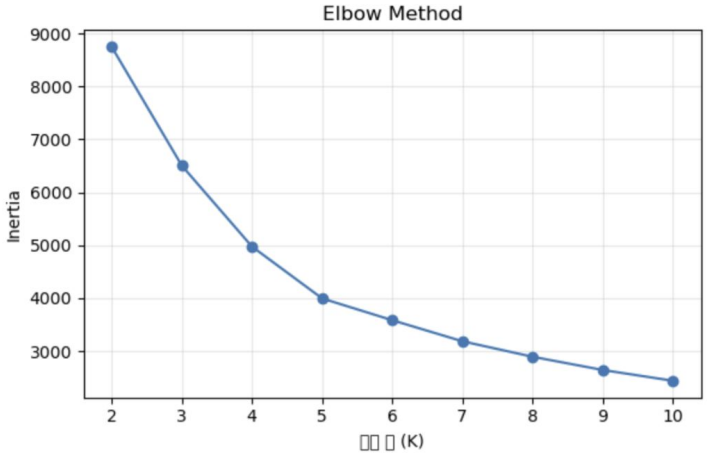
기존의 방법, K-Means

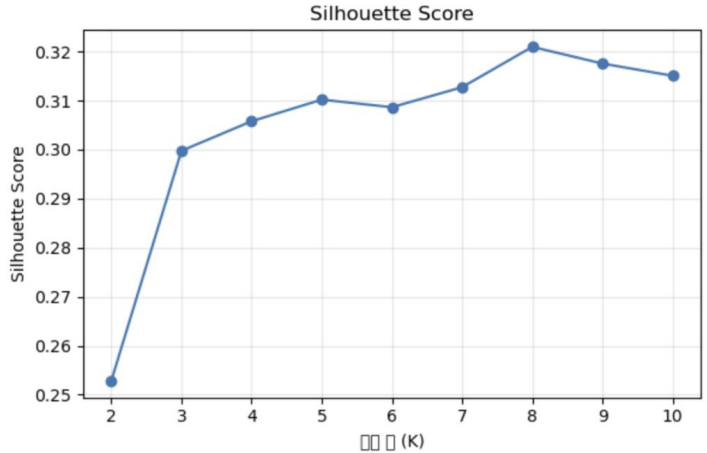
구매금액, 이전 구매횟수, 연간 구매빈도를 사용. 전처리는 StandardScaler를 사용함

K가 5일 때 응집도의 감소 속도가 줄어듦.
K가 8일 때 실루엣 점수가 가장 높았음(0.3209)

5, 8을 K의 후보로 지정

	군집 수 (K)	Inertia	Silhouette Score
0	2	8746.4029	0.2529
1	3	6502.6603	0.2997
2	4	4974.2950	0.3058
3	5	3995.2839	0.3102
4	6	3583.7711	0.3086
5	7	3186.1769	0.3127
6	8	2893.8739	0.3209
7	9	2644.1407	0.3175
8	10	2440.9090	0.3150





K=5인 K-Means일 때

대부분이 비슷한 고객 수를 가져감

Cluster_K5	고객 수	비율 (%)
0	845	21.67
1	539	13.82
2	856	21.95
3	811	20.79
4	849	21.77

K=5인 K-Means일 때

군집 0: 구매금액과 이전 구매횟수가 모두 높은 집단

군집 1: 구매빈도가 유독 높은 집단

군집 2: 구매금액은 높지만 이전 구매횟수는 낮은 집단

군집 3: 구매금액은 낮지만 이전 구매횟수는 높은 집단

군집 4: 구매금액과 이전 구매횟수가 모두 낮은 집단

군집별 구매행동 평균 (표준화 점수)

Cluster_K5	Purchase Amount (USD)	Previous Purchases	Purchase Frequency Per Year
0	0.87	0.89	-0.32
1	-0.03	0.03	2.05
2	0.86	-0.86	-0.33
3	-0.88	0.85	-0.34
4	-0.88	-0.85	-0.33

K=8인 K-Means일 때

K=5와는 다르게 좀 불균형이 발생

Cluster_K8	고객 수	비율 (%)
0	626	16.05
1	646	16.56
2	393	10.08
3	419	10.74
4	694	17.79
5	684	17.54
6	232	5.95
7	206	5.28

K=8인 K-Means일 때

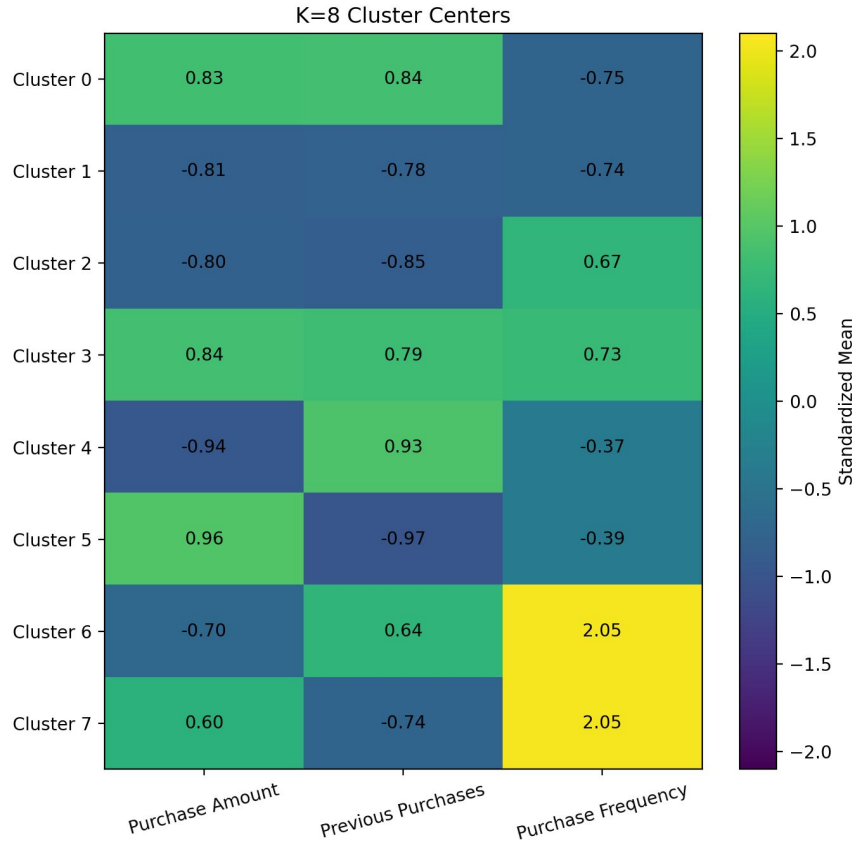
K=8에서는 구매빈도와 구매금액, 이전 구매횟수의 조합이 더욱 세분화됨.

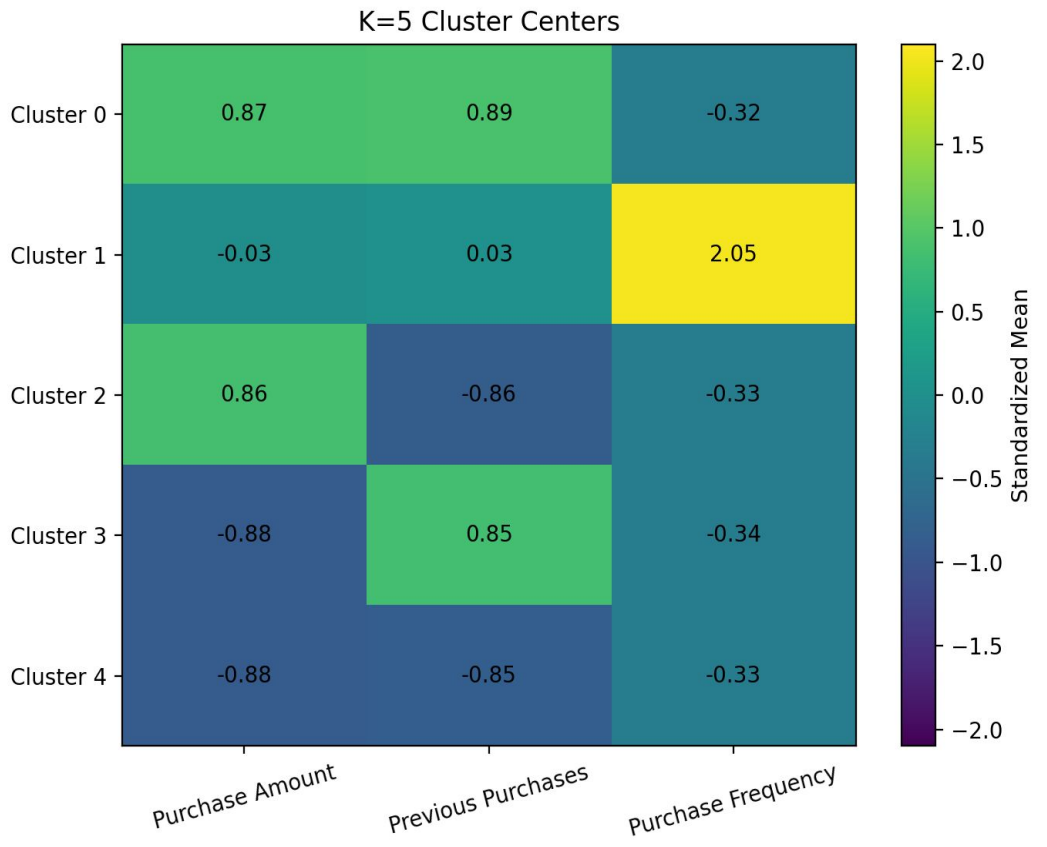
하지만 단지 그뿐인듯, 유의미한 패턴이나 통찰은 안 보임

K=8의 실루엣 점수는 0.3209로 가장 높았지만, K=5(0.3102) 대비 개선 폭(0.0107)은 작은듯 보임.

Cluster_K8	Purchase Amount (USD)	Previous Purchases	Purchase Frequency Per Year
0	0.83	0.84	-0.75
1	-0.81	-0.78	-0.74
2	-0.80	-0.85	0.67
3	0.84	0.79	0.73
4	-0.94	0.93	-0.37
5	0.96	-0.97	-0.39
6	-0.70	0.64	2.05
7	0.60	-0.74	2.05

일반 K-Means 결과 시각화





기존 K-Means 결과

요약

K-Means를 통해 소비자를 구매 행동에 따라 5, 8개 군집으로 분류.
K=8에서 가장 높은 실루엣 점수 0.3209 기록.
구매금액, 이전 구매횟수, 구매빈도에 따라 서로 다른 군집 특성 확인.

하지만

실제 거래 데이터가 아닌 합성 데이터셋을 사용하여 현실의 소비자 행동을 반영하는 데 한계 존재.
K=5 군집별 통계 검정에서 구독 여부, 구매 카테고리 등 외부 변수와의 유의미한 연관성 확인 실패.
군집 분리도가 높지 않았으며, 실제 소비자 세분화의 유용성을 입증하기 어려웠음.

앞으로

변수 선택, 전처리, 군집 수 및 알고리즘 변경을 통한 군집화 성능 개선
무작위 대조군 실험을 통한 군집의 유효성 검증

기존 구현 요약 끝.
개선 사항 발표 시작.

군집화 성능 개선 기준

학습 2,340 / 탐색용 검증 780 / 최종 평가 780으로 분리해서 실행함.

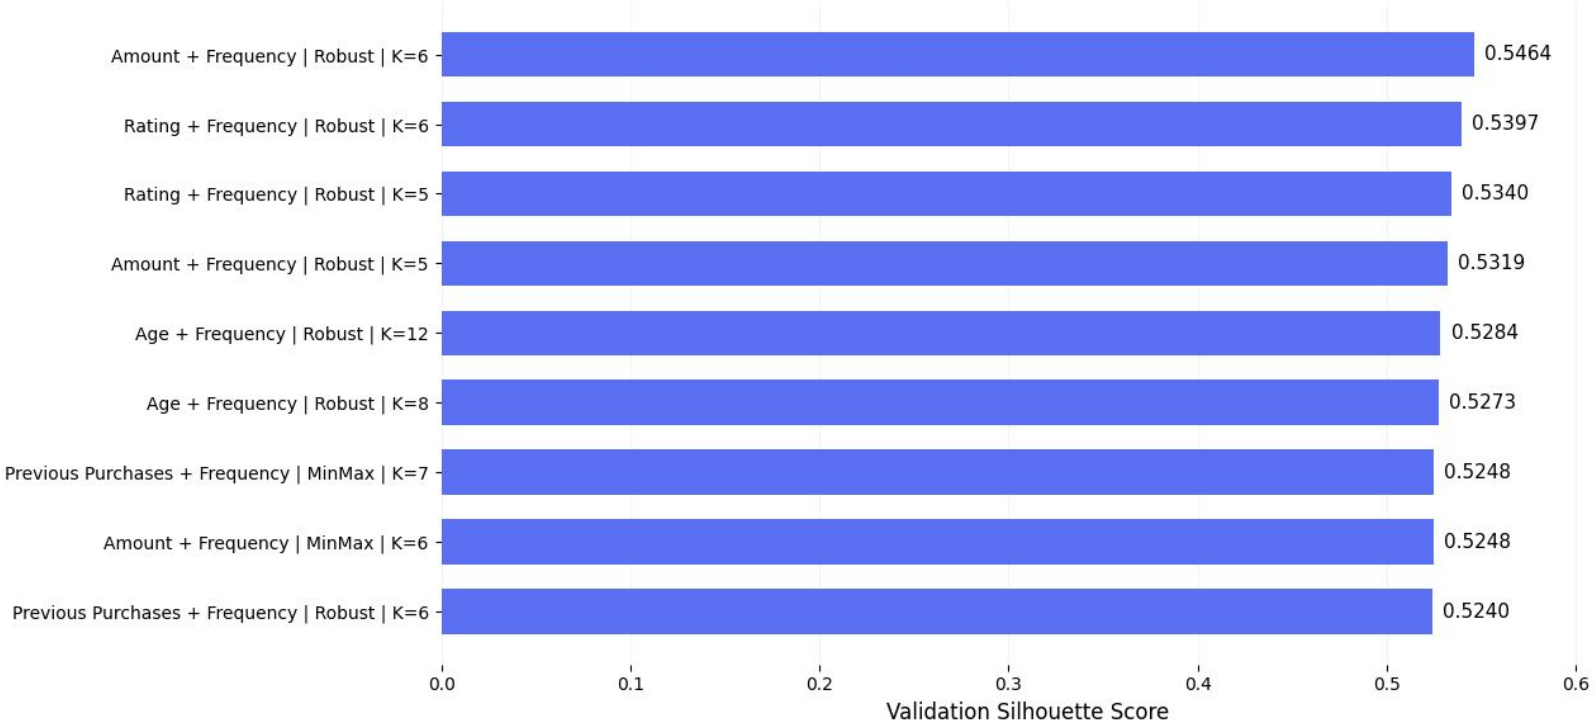
목표는 실루엣 점수를 높이는 걸 목표로 진행해봄. 데이터셋의 한계(합성 데이터임)으로 인해 유의미한 패턴은 존재하지 않아보임. 그러니까 실루엣 점수라도 높여보자.

응집도를 낮추는 게 아닌 이유는 응집도는 그냥 군집 수를 늘리면 계속 작아지니까 별 의미 없다 판단

K-Means에 전탐색 실행

변수 조합(2~3개 조합) × 5개
전처리 기법 × K값(총 990개의
조합)을 다 돌아다니면서
실루엣 점수 찾아보기

전탐색하면서 가장 점수가 높았던 10개의 특징들



사용한 전처리 기법들 간단 설명

MinMaxScaler - 데이터의 최솟값과 최댓값을 기준으로 **0~1** 범위로 변환.

StandardScaler - 평균을 **0**, 표준편차를 **1**로 변환하는 표준화 방법.

RobustScaler - 중앙값과 사분위범위를 이용해 이상치의 영향을 줄이는 정규화 방법.

QuantileTransformer - 데이터의 순위를 기반으로 균등분포 또는 정규분포로 변환.

PowerTransformer - 거듭제곱 변환을 통해 데이터 분포의 비대칭을 줄이고 분포를 대칭에 가깝게 조정.

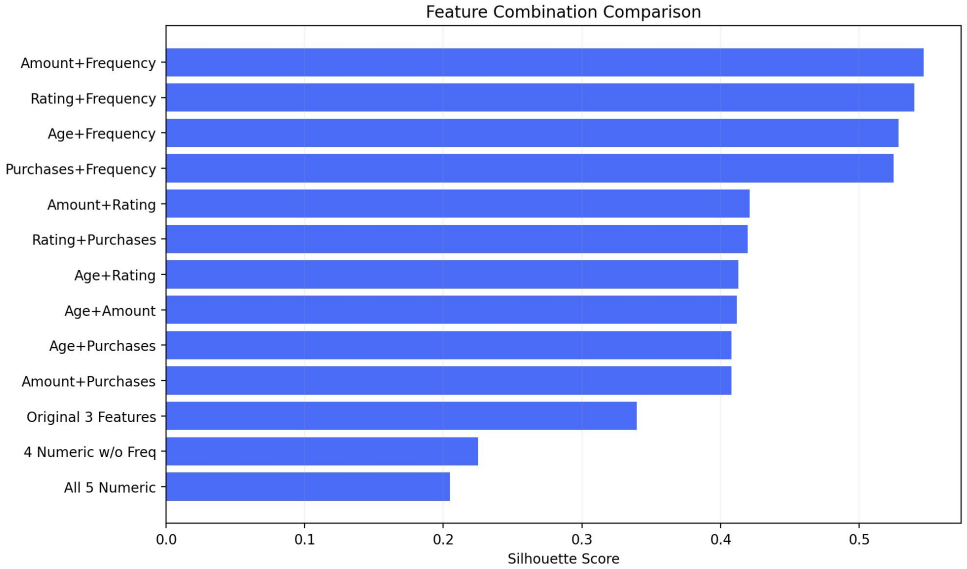
어떤 변수 선택과 전처리 기법이 좋았을까

K-Means에서는 구매금액 + 구매빈도 조합에서 가장 높은 탐색 점수 0.5464 기록함.

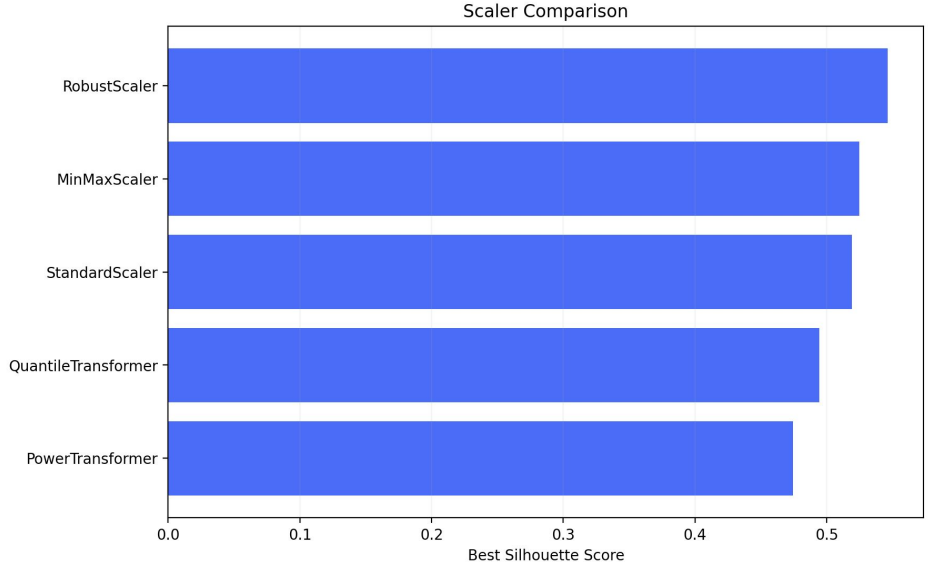
구매빈도를 포함한 변수 조합에서 높은 분리도 관측

RobustScaler 전처리 기법이 최고 탐색 결과(실루엣 점수)를 기록

Amount, Frequency



RobustScaler



사용한 군집화 기법들 간단 설명

Bisecting K-Means - 하나의 군집을 반복적으로 둘로 나누어 **K**개 군집을 생성.

GMM Full - 각 군집의 변수 간 상관관계까지 고려하는 가우시안 혼합 모델.

GMM Diagonal - 변수 간 공분산을 **0**으로 가정하는 가우시안 혼합 모델.

Agglomerative Complete - 군집 간 가장 먼 데이터의 거리를 기준으로 병합하는 계층적 군집화.

Agglomerative Ward - 군집 내 분산 증가를 최소화하며 병합하는 계층적 군집화.

BIRCH - 데이터를 압축된 트리 구조로 요약하여 효율적으로 군집화.

DBSCAN - 데이터 밀도를 기준으로 군집을 형성하고 이상치를 탐지.

HDBSCAN - 다양한 밀도의 군집을 계층적으로 탐색하고 안정적인 군집을 추출.

Spectral Clustering - 데이터 간 유사도를 그래프로 표현하고 고유벡터를 이용해 군집화.

OPTICS - 데이터의 밀도 기반 도달 가능 거리를 분석하여 다양한 밀도의 군집 구조를 탐색.

어떤 군집화 알고리즘(전탐색을 돌 때)이 좋을까

Bisecting K-Means (평점+빈도, Robust, K=6): 0.5546

GMM Full (평점+빈도, Robust, K=6): 0.5539

GMM Diagonal (평점+빈도, Robust, K=6): 0.5539

Agglomerative Complete (평점+빈도, Robust, K=6): 0.5479

Agglomerative Ward (평점+빈도, Robust, K=6): 0.5422

BIRCH (평점+빈도, Robust, K=6): 0.5406

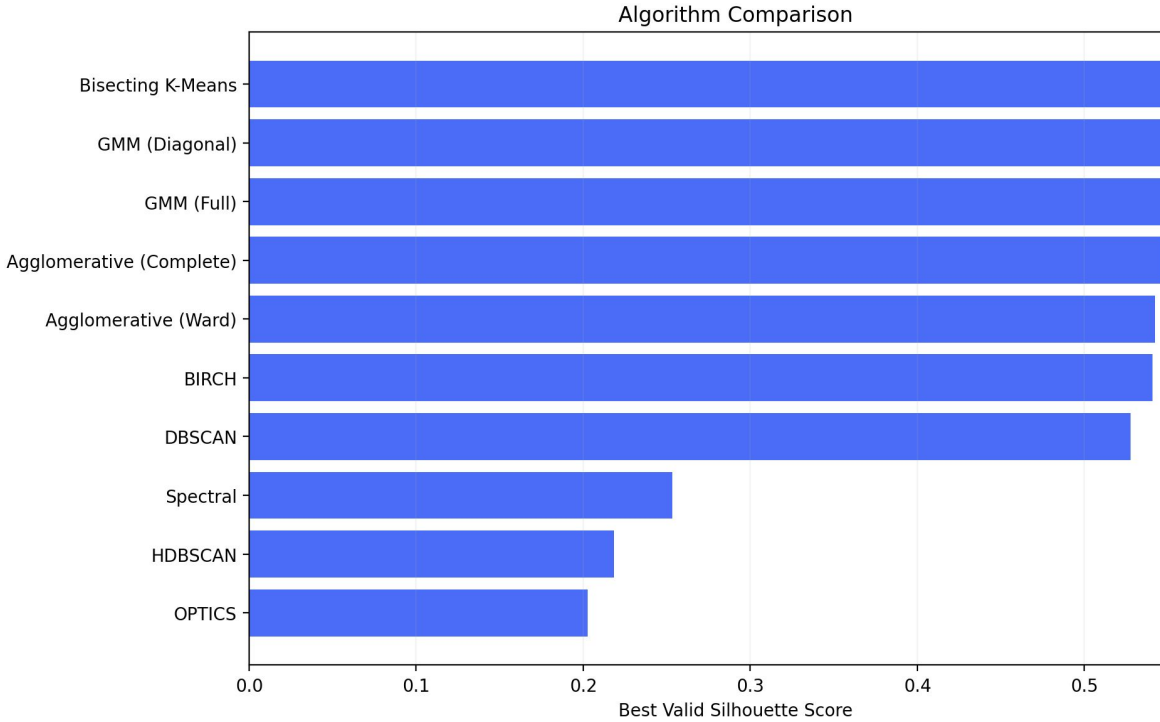
DBSCAN (금액+빈도, Robust, ε=0.7, min_samples=15 0.5276

Spectral (기존 3개 변수, Standard, K=6, n_neighbors=12): 0.2534

HDBSCAN (금액+빈도, Robust, min_cluster_size=20, min_samples=10): 0.2183

OPTICS (기존 3개 변수, Standard, min_samples=25, xi=0.05): 0.2027

Bisecting K-Means가 가장 좋더라



최종 개선 결과

Bisecting K-Means 모델에 평점과 연간 구매빈도를 변수로 사용하고 RobustScaler 전처리와 K=6을 적용했을 때 실루엣 점수가 0.5546으로 가장 높게 나타남.

기존 K-Means의 최고 점수(StandardScaler를 전처리기로 사용하고 구매 금액, 구매 빈도, 이전 구매 횟수를 변수로 사용하고 K가 8일 때)인 0.3209보다 높은 군집 분리도를 보일 뿐 아니라 가장 높은 K-Means조합(Amount + Frequency, RobustScaler전처리 사용, K=6, 실루엣 점수 = 0.5464)보다 좋은 성능을 보임.

Bisectiong K-Means에 RubustScaler 전처리를 적용하고 K는 6을 적용하고 Rating과 Frequency를 변수 조합으로 사용했을 때 모델 실루엣 점수가 가장 높더라