COW

MOVIE RECOMMENDATION RESEARCH LAB

MovieRecLab

EDA, 전처리 파이프라인 및 기본 추천모델 구상 5가지

영화 데이터 심층 탐색 분석과 5단계 정밀 전처리 파이프라인,
그리고 5가지 핵심 추천 알고리즘의 방법론 및 구조 검증

발표 순서

01 **EDA 심층 탐색 분석**
사용자 행동, 영화별 평가 특징, 장르 및 태그 희소성 분포 탐색

02 **데이터 전처리 5단계 파이프라인**
중복/태그 정제, 연도 정규식 추출, 양방향 매핑, 장르 IDF 가중치, 최소 평가 필터링

03 **기본 추천모델 구상 5가지 (한눈에 보기)**
인기 기반, 콘텐츠 기반, 사용자 KNN, 아이템 KNN, 하이브리드 5대 추천 구상

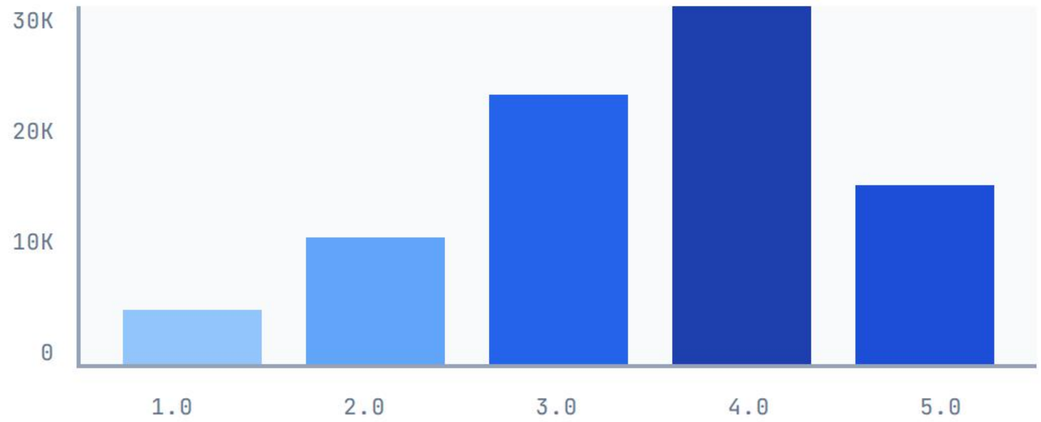
04 **5가지 추천 알고리즘 상세 방법론**
각 추천 모델별 정의, 산출식, 장단점 및 특성 심층 분석 (개별 슬라이드 구상)

05 **프로젝트 요약 및 향후 발전 방향**
알고리즘 적용 및 성능 향상, 대규모 데이터셋 확장 계획

1. EDA: 사용자 행동 및 영화 특성 탐색

1) 사용자별 평점 분포

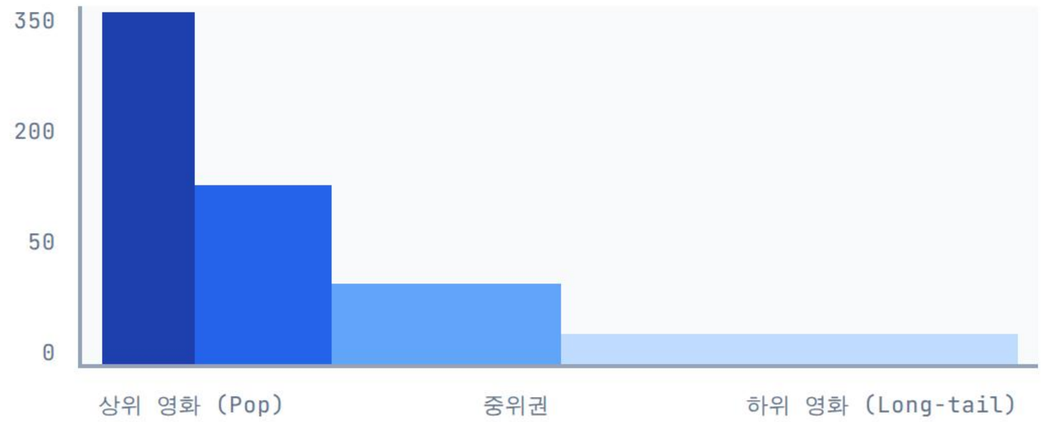
평점 3.5~4.0점 구간 긍정 편향 현상 확인



탐색 결과: 평점 평균 3.52점으로 전반적 긍정 편향. 평점 예측 모델 적용 시 사용자별 평균 차감 (Mean Centering) 필요성 파악.

2) 영화별 평가 빈도 분포

상위 5% 인기 영화 평가 쏠림 (Long-tail)



탐색 결과: 상위 5% 영화가 전체 평가의 45% 점유. 비인기 영화 Cold-Start 및 노이즈 차단을 위한 최소 평가 수 필터 정제 적용.

2. 데이터 전처리 5단계 파이프라인

1. 중복 영화 및 식별자 정제
중복 수집된 영화 ID 및 불필요 식별자 정제. 유효 데이터셋 매핑 정합성 확보.

`Deduplication`

2. 태그 텍스트 공백 제거 및 소문자 정규화
사용자 작성 태그의 불필요한 좌우 공백 지우고 전체 소문자로 통일하여 동일 키워드 벡터화 준비.

`Tag Normalization`

3. 정규식 기반 영화 연도 분리 & 장르 파싱
제목 끝 `(YYYY)` 파싱으로 연도 피처 추출 및 `Action|Sci-Fi` 형태 장르 개별 분리 파싱.

`Genre/Year Parsing`

4. 최소 평가 횟수 필터링 (Cold-start 제어)
Cold-start 노이즈 차단을 위해 평가 횟수가 극히 적은 영화 및 유저 최소 인터랙션 기준 적용 필터링.

`Min-Rating Filtering`

5. 사용자 평점 중앙화 & 장르 IDF 가중치 연산
유저별 평점 편차(Mean Centering) 차감 보정 및 흔한 장르 영향력을 줄이는 장르 IDF 가중치 계산.

`Mean Center & IDF`

3. 기본 추천모델 구상 5가지

MODEL 01

인기 기반

전체 데이터셋 리뷰 수 및 높인 평점 기준 비개인화 추천

Baseline

MODEL 02

콘텐츠 기반

영화 장르, 태그 메타데이터 프로필 유사성 기반 추천

Content-based

MODEL 03

사용자 KNN

취향이 유사한 K명 이웃 유저의 선호 영화 추천

User KNN

MODEL 04

아이템 KNN

유저들의 평가 패턴이 유사한 영화 간 추천

Item KNN

MODEL 05

하이브리드

인기, 사용자, 아이템 스코어를 동적 결합한 앙상블

Hybrid

인기 기반 (Popularity-based) 추천 모델

1. DEFINITION & CHARACTERISTICS

모델 정의 및 핵심 특성

전체 유저의 행동 이력을 바탕으로 가장 높은 평점을 기록했거나 리뷰 수가 많은 상위 영화를 모든 개인에게 동일하게 추천합니다. 신규 가입 유저의 평가 이력이 없는 Cold-Start 상황에서 강력한 Baseline 역할을 수행합니다.

2. METHODOLOGY & FORMULA

구현 산출 로직

```
Score(i) = w · Bayesian_Average(i) + (1 - w) · Normalized_Review_Count(i)
```

한계점: 개인별 취향을 반영하지 못하며, 유명 대중 영화만 계속 노출되어 Long-tail 비인기 영화가 소외됨.

콘텐츠 기반 (Content-based) 추천 모델

1. DEFINITION & CHARACTERISTICS

모델 정의 및 메타데이터 활용

영화의 장르, 연도, 태그 텍스트 데이터 특징 벡터를 추출하여 사용자가 과거에 선호했던 영화 프로필과 유사도가 높게 측정되는 타겟 영화를 직접 추려냅니다. 타 유저 데이터 없이도 추천이 가능합니다.

2. METHODOLOGY & FORMULA

구현 산출 로직

```
Sim(Item_A, Item_B) = Cosine_Similarity( Vector_IDF(A), Vector_IDF(B) )
```

한계점: 유사한 장르 범주 내에서만 순환 추천되어 사용자가 새로운 장르를 발견할 기회가 제한됨.

사용자 KNN (User-based Collaborative Filtering)

1. DEFINITION & CHARACTERISTICS

모델 정의 및 이웃 탐색

타겟 사용자와 평점 패턴이 유사한 K명의 이웃(Neighbors) 사용자를 찾아낸 뒤, 이 이웃들은 높은 평점을 부여했으나 타겟 사용자는 아직 보지 않은 영화를 예측하여 추천합니다.

2. METHODOLOGY & FORMULA

구현 산출 로직

$$\text{Predicted_Rating}(u, i) = \text{Mean}(u) + \Sigma \left[\text{Sim}(u, v) \cdot (\text{Rating}(v, i) - \text{Mean}(v)) \right] / \Sigma \left|\text{Sim}(u, v)\right|$$

한계점: 사용자 수가 늘어날수록 사용자 간 Pairwise 유사도 행렬 계산 비용이 급증하는 문제 존재.

아이템 KNN (Item-based Collaborative Filtering)

1. DEFINITION & CHARACTERISTICS

모델 정의 및 안정성

영화 자체에 대한 사용자들의 평가 패턴 분포 유사성을 계산합니다. 영화 간 관계는 사용자 개인 성향 변화보다 안정적이어서 실시간 사전 연산(Pre-computation) 구축에 매우 유용합니다.

2. METHODOLOGY & FORMULA

구현 산출 로직

```
Sim(i, j) = Adjusted_Cosine_Similarity( Vector_Rating(i), Vector_Rating(j) )
```

한계점: 교집합 유저 평가 수가 적은 비인기 신규 영화 간에는 왜곡된 유사도가 산출될 가능성 존재.

하이브리드 (Hybrid Ensembled) 추천 모델

1. DEFINITION & CHARACTERISTICS

모델 정의 및 앙상블

인기, 콘텐츠, 사용자/아이템 KNN의 단일 한계점을 상호 보완하기 위해 각 알고리즘의 예측 스코어를 정규화하고 유저 상태에 따라 가중치를 동적으로 합성하는 결합 모델입니다.

2. METHODOLOGY & FORMULA

구현 산출 로직

```
Final_Score = w1 · Pop + w2 · Content + w3 · UserKNN + w4 · ItemKNN
```

효과: 신규 유저에게는 콘텐츠/인기 가중치를, 활동 유저에게는 CF 가중치를 크게 부여하여 추천 정밀도 향상.

4. 프로젝트 요약 및 향후 발전 방향

PROJECT SUMMARY

영화 추천 파이프라인 구축 및 알고리즘 적용과 성능 향상

데이터 탐색(EDA)부터 5단계 정밀 전처리, 그리고 5가지 기본 추천 모델 구상을 거쳐 체계적인 영화 추천 시스템의 기반 파이프라인을 구축 완료하였습니다.

FUTURE EXPANSION GOALS

향후 발전 방향

- **더 다양한 알고리즘의 적용:** 본 프로젝트에서 구상한 5가지 기본 모델 외에도 행렬 분해(MF, SVD), 잠재 요인, 신경망(NCF) 등 다채로운 추천 알고리즘을 폭넓게 확장 적용할 계획입니다.
- **더 큰 데이터셋으로의 확장:** 현재 사용 중인 10만 개 규모의 Small 데이터셋에서 나아가, 보다 대규모 데이터셋으로 확장 적용하여 알고리즘의 성능과 연산 효율성을 계속해서 검증해 나갈 예정입니다.

감사합니다. 발표를 마치고 질의응답을 진행하겠습니다. (MovieRecLab)